

Contents

1. Introducción	1
2. Descripción de la base de datos	2
3.Exploración y preparación de los datos	2
4. Modelos aplicados	2
5. Resultados	3
6. Discusión	4
7. Conclusiones	5

Colegio Universitario de Cartago

Proyecto Final

Grupo E

Integrantes: Sharon Obando Gómez Fiorella Abarca Valverde Monica Mendoza Morales Roberto Montoya Leiva Roberto Coto Guevara

Carrera: Big Data

Materia: BD-165 · Modelos Estadísticos Avanzados

Profesor: David Martínez Salazar

14 de agosto de 2026

1. Introducción

El análisis de datos se ha convertido en una herramienta clave para muchas empresas en la actualidad. Gracias a varias técnicas, las empresas pueden entender mejor el comportamiento de sus clientes, sus productos y sus ventas, identificando patrones, diferencias entre grupos o relaciones entre variables de forma automática, algo que antes solo se podía hacer de manera superficial revisando los datos a simple vista.

Para este proyecto, trabajamos con la base de datos Superstore Dataset, que contiene información de ventas de una tienda en Estados Unidos, con 9.994 registros entre variables numéricas y categóricas. Sobre esta base se aplicaron tres técnicas de análisis multivariado, cada una respondiendo una pregunta distinta: ANOVA - MANOVA, que permiten identificar si existen diferencias significativas en las ventas y la ganancia según grupos ya definidos, como la región de venta o el tipo de producto; Regresión, que permite explicar o predecir una variable numérica en función de otras; y Análisis de Cluster, que permite descubrir grupos o patrones dentro de los datos que no estaban definidos de antemano. Cada una de estas técnicas aporta una perspectiva distinta y, en conjunto, permiten tener una visión más completa del comportamiento de la tienda.

El mundo del análisis de datos cambia constantemente, por lo que es importante conocer y saber aplicar distintas técnicas estadísticas y cómo estas pueden facilitar la toma de decisiones en un negocio. Por lo tanto, el propósito de nuestra investigación es aplicar ANOVA - MANOVA, Regresión y Análisis de Cluster sobre la base de datos Sample Superstore, con el fin de identificar qué factores explican mejor el comportamiento de las ventas y la ganancia de la tienda, y si es posible reconocer patrones o grupos dentro de los datos que ayuden a tomar mejores decisiones de negocio. Además, se busca complementar esta investigación con la interpretación de los resultados obtenidos en cada técnica, evidenciando su utilidad dentro del análisis de datos.

2. Descripción de la base de datos

Kaggle: <https://www.kaggle.com/datasets/vivek468/superstore-dataset-final>

La base de datos se llama **Superstore Dataset** y la conseguimos en Kaggle. Tiene información de una tienda de ventas, con 9,994 registros (filas) y 21 columnas, entre las que están:

Variables categóricas: Región (Region), Categoría del producto (Category), Sub-categoría (Sub-Category), Segmento de cliente (Segment), Modo de envío (Ship Mode), entre otras.

Variables numéricas: Ventas (Sales), Ganancia (Profit), Cantidad (Quantity), Descuento (Discount).

No tuvimos que buscar datos faltantes ni nada raro, la base venía bastante limpia.

3.Exploración y preparación de los datos

Cluster

Para el clustering, lo primero que tuvimos que hacer fue transformar la base, porque originalmente venía organizada por línea de pedido (un mismo cliente podía aparecer en varias filas, una por cada compra). Pero para agrupar clientes necesitábamos una sola fila por cliente, así que juntamos toda su información en variables como: cuántos días pasaron desde su última compra, cuántas órdenes distintas hizo, cuánto gastó en total, cuánta ganancia generó y qué tanto descuento recibía en promedio.

También revisamos que no hubiera datos faltantes (no había ninguno) ni filas duplicadas, y encontramos 43 clientes con montos de compra bastante más altos que el resto (outliers). Decidimos dejarlos, porque lo más probable es que sean cuentas grandes reales y no errores en los datos.

Por último, como estas variables estaban en escalas muy distintas (por ejemplo, dinero gastado en dólares versus un descuento que va de 0 a 1), tuvimos que estandarizarlas antes de meterlas al modelo, para que ninguna variable “pesara” más que otra solo por tener números más grandes.

Regresion

Para la regresión usamos las variables numéricas de la base: ganancia, ventas, cantidad y descuento, y además calculamos una nueva variable (días que tardaba en llegar cada pedido) restando la fecha de envío menos la fecha de la orden. Quitamos las filas que tuvieran algún dato faltante en estas columnas para que el modelo no tuviera problemas al momento de ajustarse.

ANOVA - MANOVA

Antes de realizar cualquier prueba, primero se realizó un cambio en las variables de Region, Category y Segment estaban guardadas como texto (character) en vez de como variable categórica, las convertimos a factor, que es como R reconoce que esas columnas representan grupos y no simple texto.

También revisamos cuántas observaciones había en cada grupo: notamos que no estaban parejas (por ejemplo, la región West tiene muchas más ventas registradas que South), pero eso no impide realizar el análisis.

4. Modelos aplicados

¿Por qué usamos Cluster?

Usamos clustering porque queríamos agrupar a los clientes según su comportamiento de compra, sin tener grupos ya definidos de antemano (a diferencia de ANOVA, donde ya sabíamos los grupos (región, categoría)). Probamos tres métodos distintos para ver cuál agrupaba mejor: K-means (arma grupos redondos alrededor de un centro), clustering jerárquico (va uniendo clientes parecidos poco a poco hasta formar un árbol de agrupaciones) y DBSCAN (agrupa según qué tan “pegados” están los clientes entre sí). Usar los tres nos permitió comparar resultados y quedarnos con el que mejor separara a los clientes.

¿Por qué usamos Regresión?

Usamos regresión porque queríamos ver si podíamos explicar o predecir la ganancia de una venta a partir de otras variables, como el monto vendido, la cantidad de productos, el descuento aplicado y los días que tarda el envío. A diferencia de ANOVA, que compara promedios entre grupos ya definidos, la regresión nos deja ver cómo cambia una variable numérica cuando cambian otras variables numéricas relacionadas, y hasta hacer predicciones para ventas nuevas que todavía no han pasado.

¿Por qué usamos ANOVA - MANOVA?

Se utiliza ANOVA, ya que, se quiere comparar si la ganancia promedio (Profit) cambia dependiendo de la región donde se hace la venta (Region). Como región tiene 4 grupos, no podíamos usar solo una prueba t normal, que solo iba a comparar dos grupos, por lo tanto, para comparar varios grupos a la vez, se utiliza ANOVA que es la herramienta correcta.

Se utiliza MANOVA, ya que, se quería ver si la categoría del producto y el segmento de cliente influyen al mismo tiempo en dos variables relacionadas: las ventas y la ganancia. Como estas dos variables están correlacionadas entre sí, no era correcto analizarlas por separado con dos ANOVAS, porque se estaría perdiendo esa relación entre ambas. El MANOVA nos permite analizarlas juntas como un solo vector de respuesta.

5. Resultados

Cluster

Para decidir cuántos grupos usar, aplicamos el método del codo y el análisis de silueta, y ambos coincidieron en que 4 grupos era la mejor opción. Con K-means armamos esos 4 grupos:

Grupo 1 (59 clientes): los más valiosos, ya que, compran seguido, gastan mucho (en promedio 9,321) y generan la mayor ganancia (\$2,229 en promedio). Les llamamos clientes VIP.

Grupo 2 (204 clientes): compran poco, gastan poco, y lo más importante le están generando pérdidas a la tienda (ganancia promedio negativa), probablemente porque reciben demasiado descuento (25.6% en promedio).

Grupo 3 (267 clientes, el más grande): compran poco y gastan poco, igual que el grupo 2, pero a diferencia de ellos sí generan ganancia positiva, porque reciben mucho menos descuento. Son clientes de bajo valor pero rentables.

Grupo 4 (263 clientes): compran seguido y gastan una cantidad intermedia, con una ganancia parecida al grupo 3. Son clientes frecuentes y razonablemente rentables.

También probamos clustering jerárquico y confirmó básicamente los mismos 4 grupos, así que los resultados son consistentes entre métodos. DBSCAN, en cambio, no logró separar a los clientes en varios grupos metió a casi todos en un solo grupo grande y solo marcó 40 clientes como “raros” o atípicos. Comparando los tres métodos con la silueta (una medida de qué tan bien separados están los grupos), K-means fue el que mejor resultado dio, así que nos quedamos con ese.

Regresion

Probamos varios modelos para explicar la ganancia. El modelo con las 4 variables (ventas, cantidad, descuento y días de envío) solo explicaba un 27% de la variación ($R^2 = 0.27$), y los días de envío no aportaban nada, así que se quitaron.

El modelo que mejor funcionó fue el que incluye la interacción entre ventas y descuento, es decir, dejando que el efecto del descuento cambie según qué tanto se esté vendiendo. Este modelo subió a explicar un 72% de la variación en la ganancia ($R^2 = 0.72$), con mejor AIC y BIC que los demás, así que fue el que se usó como final.

Con este modelo encontramos que más ventas significan más ganancia, más cantidad por orden reduce un poco la ganancia, y sobre todo que el descuento afecta mucho más fuerte a la ganancia cuando la venta es grande, dar descuento en ventas altas le pega más duro al negocio que en ventas pequeñas.

Los supuestos de la regresión (normalidad, varianza pareja) no se cumplieron, algo esperable con una base tan grande. Por eso se corrió el modelo también con errores estándar robustos, y las mismas variables siguieron siendo significativas, lo que da más confianza en el resultado.

Por último, se usó el modelo para predecir: una venta de \$500, cantidad 3 y 10% de descuento da una ganancia estimada de \$116.51, con un intervalo de predicción del 95% entre \$127.53 y \$360.55, un rango amplio que muestra bastante incertidumbre para predicciones individuales.

ANOVA - MANOVA

Resultados del ANOVA (Profit según Region)

Lo primero fue revisar si se cumplían los supuestos necesarios (normalidad y que las varianzas fueran parecidas entre grupos). En este caso, como teníamos miles de datos por región, la prueba de normalidad salió que no se cumple, y la de varianzas iguales tampoco. Esto es algo normal cuando se trabaja con bases de datos grandes, no es que se realizó algo mal.

Aun así, seguimos con el ANOVA porque con tantos datos, el resultado sigue siendo confiable de todas formas. El resultado que obtuvimos fue:

$F = 2.622$, valor $p = 0.0489$

Como el valor p es menor a 0.05, técnicamente sí hay una diferencia significativa entre las regiones, pero está muy al límite, lo que nos dice que la diferencia real entre regiones no es tan fuerte.

Para saber exactamente entre qué regiones estaba la diferencia, se realizó la prueba de Tukey, que compara los grupos de dos en dos. De las 6 comparaciones posibles, solo una salió con diferencia real: West contra Central (valor $p = 0.043$). Las demás comparaciones no mostraron diferencias.

En el gráfico de boxplot se puede ver que la región Central tiene la ganancia promedio más baja, mientras que West, East y South están más parejas entre sí y un poco más arriba.

Resultados del MANOVA (Sales y Profit según Category y Segment)

Al igual que con el ANOVA, revisamos los supuestos antes de realizar la prueba, y en este caso ninguno se cumplió completamente (otra vez, por la cantidad tan grande de datos). Aun así se realizó el MANOVA porque el tamaño de muestra grande le da robustez a la prueba.

Los resultados fueron:

Categoría del producto: valor p menor a 0.001 $\rightarrow$ sí hay diferencia significativa Segmento de cliente: valor $p = 0.748 \rightarrow$ no hay diferencia significativa Interacción entre categoría y segmento: valor $p = 0.4036 \rightarrow$ tampoco hay diferencia significativa

Esto quiere decir que el tipo de producto (Furniture, Office Supplies o Technology) sí afecta las ventas y la ganancia, pero el tipo de cliente (Consumer, Corporate o Home Office) no hace ninguna diferencia. Se revisó esto también por separado para Ventas y para Ganancia, y en ambos casos se repite exactamente el mismo patrón: solo la categoría del producto importa.

En el gráfico de líneas se nota que la categoría Technology tiene las ventas más altas en todos los segmentos, seguida de Furniture, y por último Office Supplies con las ventas más bajas, y esas diferencias se mantienen igual sin importar el segmento de cliente, lo cual confirma que no hay interacción entre las dos variables.

6. Discusión

Cluster

Con el clustering nos dimos cuenta de que no todos los clientes valen lo mismo para la tienda. Hay un grupo pequeño (los VIP) que genera muchísima ganancia, y también hay un grupo que, aunque compran, le está generando pérdidas a la tienda por el exceso de descuentos que recibe. Esto es información súper útil para el negocio, se podrían enfocar más esfuerzos en cuidar a los clientes VIP, y revisar la política de descuentos para el grupo que está generando pérdidas.

Regresion

Lo que más nos llamó la atención fue que agregar la interacción entre ventas y descuento cambió por completo la calidad del modelo (de 27% a 72% de variación explicada). Esto nos enseña que, en este negocio, el descuento no afecta igual a todas las ventas — no es lo mismo dar 20% de descuento en una venta pequeña que en una venta grande, y un modelo que no tomara en cuenta esa interacción se estaría perdiendo la parte más importante de la historia.

ANOVA - MANOVA

Con estos resultados podemos decir que el lugar donde se vende (Region) tiene un efecto débil sobre la ganancia, mientras que el tipo de producto tiene un efecto mucho más claro y fuerte tanto en ventas como en ganancia. Por otro lado, a quién se le vende (Segmento de cliente) no parece tener ningún impacto.

Una limitación importante que se debe mencionar es que, al trabajar con una base de datos tan grande, no se cumplieron los supuestos estadísticos que normalmente se piden para estas pruebas (normalidad y varianzas iguales). Esto no quiere decir que invalida el análisis por completo, pero sí es algo que hay que se debe tener presente al interpretar los resultados, con estos datos rara vez todo sale como **‘perfecto’** como en un ejemplo de clase, y hay que saber reconocer esas limitaciones en vez de solo ignorarlas.

7. Conclusiones

Cluster

- El clustering nos permitió identificar 4 grupos de clientes claramente diferenciados según su comportamiento de compra, uno de clientes VIP, uno que genera pérdidas, y dos grupos intermedios de distinto tamaño y rentabilidad.
- K-means fue el método que mejor separó a los clientes, y sus resultados se confirmaron con clustering jerárquico, lo que nos da confianza en que estos grupos son reales y no producto del azar.

Regresion

- El modelo que mejor explica la ganancia es el que incluye la interacción entre ventas y descuento, explicando un 72% de su variación, mucho mejor que el modelo simple sin interacción.
- El descuento es la variable que más le afecta negativamente a la ganancia, y ese efecto se vuelve más fuerte mientras mayor es la venta, algo clave para replantear la política de descuentos de la tienda.

ANOVA - MANOVA

- El análisis de ANOVA mostró que la ganancia sí varía entre regiones, pero la diferencia es débil y se concentra solo entre la región con mayor ganancia (West) y la de menor ganancia (Central).
- El análisis de MANOVA mostró que la categoría de producto es el factor que realmente marca una diferencia en el comportamiento de ventas y ganancia, mientras que el segmento de cliente no influye.
- En conjunto, estos resultados sugieren que, para esta tienda, las decisiones de negocio deberían enfocarse más en qué tipo de producto se vende que en dónde se vende o a qué tipo de cliente se le vende.